


Конспект

▼ Що таке AI/DS/ML/DL?

Що таке Штучний Інтелект (ШІ)?



Штучний Інтелект (ШІ) - це галузь науки, яка ставить за мету створення систем, які можуть виконувати завдання, які зазвичай вимагають інтелекту людини. Штучний інтелект орієнтований на розробку програм та алгоритмів, які надають комп'ютерам здатність вирішувати проблеми, вчитися з досвіду та самостійно приймати рішення.

Термін "Штучний Інтелект" був введений в 1950-х роках. З того часу ШІ розвивався від теоретичних концепцій до конкретних технологій. Перші десятиліття розвитку були визначені обмеженими обчислювальними можливостями та відсутністю значущих наборів даних. Проте в останні десятиріччя ШІ зазнав значного прогресу завдяки зростанню потужності обчислювальної техніки та розвитку методів машинного навчання, зокрема глибокого навчання.


Сьогодні Штучний Інтелект використовується в різних галузях, таких як медицина, фінанси, автомобільна промисловість, технічне обслуговування

та інші, щоб вирішувати складні завдання та сприяти автоматизації процесів.


Важливою частиною Штучного Інтелекту є Машинне Навчання, яке дозволяє системам вдосконалювати свою продуктивність, навчаючись на великих обсягах даних, і Глибоке Навчання, яке використовує глибокі нейронні мережі для вирішення завдань, що раніше вважалися важкими для автоматизації.

Що таке Машинне Навчання?

TRADITIONAL PROGRAMMING



MACHINE LEARNING



Машинне Навчання - це конкретна галузь штучного інтелекту, яка зосереджена на розробці систем, які можуть автоматично навчатися та покращувати свою продуктивність без явного програмування. В основі машинного навчання лежить ідея створення моделей, які можуть адаптуватися до нової інформації та робити прогнози чи приймати рішення на основі вивченого досвіду.


Ідеї, що лягли в основу Машинного Навчання, виникали ще в середині 20-го століття. Однак справжній прорив відбувся в 1950-60-х роках. Одним із раніших успіхів було створення програм, яка грала в шахи.

У 1980-90-х роках виникла нова хвиля інтересу до Машинного Навчання, зумовлена розвитком комп'ютерів та збільшенням доступності обчислювальних ресурсів. З цього часу і до наших днів Машинне Навчання стрімко розвивалося, стаючи ключовою галуззю Штучного Інтелекту.

Зокрема, зростання обсягу доступних даних та розвиток глибокого навчання в останні роки принесли значний прогрес у цій сфері.

Сьогодні Машинне Навчання широко застосовується в різних галузях, таких як медицина, фінанси, технічне обслуговування, електронна комерція та інші, демонструючи потенціал для розв'язання різноманітних завдань та оптимізації процесів.

Що таке Глибоке Навчання?




Глибоке Навчання - це підгалузь машинного навчання, яка використовує нейронні мережі з численними шарами (глибокі нейронні мережі) для вирішення завдань. Глибоке навчання намагається моделювати високорівневі абстракції в даних, що дозволяє автоматизовано виявляти складні залежності та патерни.


Історія Глибокого Навчання налічує кілька етапів. Перші спроби використання глибоких нейронних мереж відбулися ще в 1960-70-х роках. Проте на той час розвиток цієї технології був обмеженим через відсутність необхідних обчислювальних ресурсів та ефективних алгоритмів.

Справжній прорив відбувся в 2010-х роках завдяки кільком факторам. Зокрема, зростання потужності обчислювальних пристроїв, збільшення об'єму доступних даних та розвиток нових методів навчання. Визнанням успіхів Глибокого Навчання став конкурс ImageNet в 2012 році, коли глибока нейронна мережа здобула вражаючий успіх у класифікації зображень.

Відтоді Глибоке Навчання стало ключовим напрямком в Машинному Навчанні, знаходячи застосування в різних сферах, таких як комп'ютерний зір, обробка природної мови, автономні автомобілі та інші. Воно вирішує завдання, які раніше вважалися вкрай складними, завдяки здатності вивчати високорівневі абстракції в даних та розпізнавати складні патерни.



Що таке Data Science?



Data Science - це галузь, яка об'єднує методи та процеси для отримання, обробки та аналізу великих обсягів даних. Data Science використовує інструменти зі статистики, математики та програмування для винесення інсайтів, розробки прогнозів та прийняття рішень на основі отриманих даних. У контексті штучного інтелекту, Data Science є ключовим етапом для підготовки та обробки даних, які використовуються для навчання моделей та вирішення завдань.


Ключові етапи в Data Science:

1. Збір даних (Data Collection):

- Збір різноманітних даних з різних джерел, таких як бази даних, веб-сервери, датчики, соціальні мережі та інші джерела.
2. Очищення даних (Data Cleaning):
 - Видалення аномальних або неправильних даних, заповнення пропущених значень, агрегація та перетворення даних для подальшого аналізу.
 3. Розвідувальний аналіз даних (Exploratory Data Analysis - EDA):
 - Вивчення основних характеристик даних, виявлення взаємозв'язків та визначення можливих патернів.
 4. Моделювання (Modeling):
 - Розробка та навчання моделей для прогнозування, класифікації або вирішення конкретних завдань, використовуючи алгоритми машинного навчання.
 5. Валідація та Тестування (Validation and Testing):
 - Перевірка ефективності моделей на незалежних наборах даних для гарантії їхньої точності та генералізації.
 6. Визначення інсайтів та Прийняття рішень (Insights and Decision Making):
 - Винесення інсайтів на основі аналізу даних та використання отриманих знань для прийняття інформованих стратегічних рішень.
 7. Візуалізація (Data Visualization):
 - Представлення результатів аналізу та визначених залежностей за допомогою графіків, діаграм та інших візуальних засобів.

▼ Роль математики в ML

Роль математики в Machine Learning



1. Представлення та обробка даних:

- Математика використовується для представлення даних у вигляді матриць та векторів. Для числових даних, зображень, текстів та інших типів інформації використовуються матриці для зручності обробки та аналізу.

2. Оптимізація алгоритмів:

- Математика важлива в машинному навчанні для оптимізації алгоритмів. Операції з матрицями дозволяють прискорити обчислення, зменшуючи час виконання алгоритмів та зменшуючи обчислювальну складність.

3. Моделі машинного навчання:

- Багато алгоритмів машинного навчання, такі як лінійна регресія та класифікатори, базуються на лінійних операціях з матрицями. Знання математики допомагає ефективно працювати з цими моделями та розуміти їх поведінку.

4. Вимірювання та аналіз відстаней:

- Математика використовується для вимірювання відстаней між об'єктами у просторі функцій. Це корисно при визначенні схожості

об'єктів та для розв'язання задач кластеризації.

5. Вирішення систем лінійних рівнянь:

- У багатьох випадках машинного навчання виникають системи лінійних рівнянь, які потрібно розв'язати для знаходження оптимальних параметрів моделей чи для вирішення інших завдань.

6. Навчання моделей та градієнтний спуск:

- Градієнтний спуск, який є основною технікою оптимізації в навчанні моделей, використовує математику для обчислення похідних та оновлення параметрів моделі.

▼ Роль статистики в ML

Роль статистики в Machine Learning

1. Оцінка та розуміння даних:

- Статистика допомагає в описі та узагальненні важливих характеристик наборів даних, таких як середнє значення, медіана, дисперсія та інші статистичні параметри, для кращого розуміння їхнього розподілу та особливостей.

2. Виділення важливих ознак та відбір змінних:

- Знання статистики допомагає вибрати та розуміти важливі ознаки в наборі даних. Методи, такі як аналіз дисперсії та кореляції, використовуються для визначення впливу ознак на вихідні змінні.

3. Оцінка моделей та їхніх параметрів:

- Статистика використовується для оцінки точності та надійності моделей машинного навчання. Інтервали довіри, тестування гіпотез та інші статистичні методи дозволяють робити висновки щодо стабільності та об'єктивності результатів.

4. Крос-валідація та вибір моделей:

- Використання методів крос-валідації та перехресної перевірки допомагає у виборі оптимальної моделі та уникненні перенавчання чи недонавчання.

5. Статистична обробка помилок:


- Статистика використовується для аналізу та обробки помилок моделей, що допомагає зрозуміти, наскільки точно модель передбачає результати та які частини моделі вимагають поліпшень.

6. Регуляризація та управління перенавчанням:

- Статистика допомагає в контролі та управлінні перенавчанням моделей, включаючи використання регуляризації та вагових коефіцієнтів для управління складністю моделей.


Статистика в машинному навчанні використовується для розуміння, оцінки та управління невизначеністю та ризиками, які пов'язані з аналізом даних та побудовою моделей. Це забезпечує об'єктивність та достовірність в процесі прийняття рішень на основі даних.

▼ Задачі, що вирішує ML



Що таке Supervised Learning в ML?

Supervised Learning



Supervised Learning (навчання з вчителем) - це тип задачі в Машинному Навчанні, де модель навчається на основі пар даних вхід-вихід. Мета полягає в тому, щоб навчити модель знаходити взаємозв'язки та патерни між вхідними даними і відповідними вихідними мітками (таргетами). У Supervised Learning алгоритм отримує навчальний набір, де кожен приклад має відомий вихід, і завданням є навчити модель передбачати вихід для нових, раніше невідомих вхідних даних.

Приклади Supervised Learning:

1. Класифікація електронної пошти:

- Задача: Визначити, чи є електронний лист спамом чи неспамом.
- Вхідні дані: Заголовок, текст та інші атрибути листа.
- Вихідні дані: Спам чи не спам.

2. Розпізнавання об'єктів в зображеннях:

- Задача: Визначити, що зображено на зображенні (наприклад, кіт, собака, автомобіль).
- Вхідні дані: Пікселі кольорового зображення.
- Вихідні дані: Клас об'єкта (кіт, собака, автомобіль тощо).

3. Прогнозування цін на нерухомість:

- Задача: Передбачити вартість нерухомості на основі різних факторів (площа, розташування, кількість кімнат).
- Вхідні дані: Характеристики нерухомості.
- Вихідні дані: Оцінена вартість.

4. Аналіз кредитного ризику:

- Задача: Визначити ймовірність того, що клієнт не поверне кредит.
- Вхідні дані: Фінансові дані клієнта (дохід, кредитна історія).
- Вихідні дані: Ймовірність неповернення кредиту.


5. Медична діагностика:

- Задача: Визначити наявність захворювання на основі медичних зображень чи аналізів.
- Вхідні дані: Зображення, рентгенограми, медичні показники.
- Вихідні дані: Діагноз захворювання.

Supervised Learning є одним із найрозповсюдженіших підходів в Машинному Навчанні і знаходить широке застосування в різних сферах.

Що таке Unsupervised Learning в ML?

Unsupervised Learning



Unsupervised Learning (навчання без вчителя) - це тип задачі в Машинному Навчанні, де модель працює з набором даних, де вихідні мітки або категорії відсутні. Основна мета полягає в тому, щоб модель знаходила природні структури або патерни в даних, розкриваючи приховані зв'язки чи групи. У цьому випадку алгоритм намагається визначити структуру даних без конкретних вказівок щодо правильних відповідей.

Приклади Unsupervised Learning:

1. Кластеризація:

- Задача: Групування схожих об'єктів в кластери.
- Приклад: Кластеризація покупців в інтернет-магазині на основі їхніх покупок для подальшої персоналізації пропозицій.

2. Зниження розмірності (Dimensionality Reduction):


- Задача: Зменшення кількості атрибутів (розмірності) у наборі даних, зберігаючи при цьому основні характеристики.
- Приклад: Перетворення зображень в інший простір розмірності для полегшення обробки та зменшення обсягу даних.

3. Генеративні моделі:

- Задача: Створення нових прикладів.
- Приклад: Генерація зображень або створення нових прикладів тексту на основі існуючих текстових описів.

Unsupervised Learning є корисним для виявлення прихованих шаблонів у наборах даних, що може призводити до нових інсайтів та розуміння природи даних без вказівок чи наперед заданих відповідей.

Що таке Reinforcement Learning в ML?



Reinforcement Learning (навчання з підкріпленням) – це тип Машинного Навчання, де агент навчається приймати рішення в середовищі з метою максимізації деякого числового показника винагороди. В цьому контексті, агент діє в середовищі, спостерігає за його станом і вибирає дії, щоб здобути максимальну нагороду. Алгоритм агента вирішує, які дії призводять до найкращих результатів, враховуючи вивчений досвід та винагороду за кожну взятую дію.

Приклади Reinforcement Learning:

1. Гра в Го:

- Агент: Комп'ютерний гравець, який вчиться грати в Го.
- Середовище: Гральна дошка та плитки для каменів.
- Дії: Розміщення каменів на дошці.
- Винагорода: Виграш або програш в грі.

2. Управління роботом:

- Агент: Робот, який навчається виконувати завдання.
- Середовище: Робочий простір робота.
- Дії: Рухи та маніпуляції робота.
- Винагорода: Успішне виконання завдання.


3. Вивчення стратегій у відеоіграх:

- Агент: Віртуальний гравець у відеоіграх.
- Середовище: Гральна платформа.
- Дії: Рухи, стрільба, ухилення від ворожих атак.
- Винагорода: Набуття балів та досягнення гри.

Reinforcement Learning застосовується в ситуаціях, де агент повинен приймати послідовні рішення, а його дії впливають на подальший розвиток ситуації, а також на винагороду, яку він отримує.

▼ Етапи реалізації проєктів з ML

Що таке CRISP-DM (Cross-Industry Standard Process for Data Mining)?



CRISP-DM - це стандартний процес для ведення проектів з обробкою даних (Data Mining), який включає в себе етапи та завдання, щоб впоратися з комплексністю та невизначеністю в процесі аналізу даних. Ця методологія розділена на шість основних етапів, які взаємодіють між собою:

1. Розуміння бізнес-проблеми (Business Understanding):

- Мета: Зрозуміти бізнес-задачі та визначити цілі проекту.

- Приклад: Банк, який хоче покращити виявлення шахрайства в банківських транзакціях.

2. Розуміння даних (Data Understanding):

- Мета: Збір, ознайомлення та оцінка доступних даних для визначення їхньої придатності для вирішення завдань проєкту.
- Приклад: Оцінка структури даних з банківськими транзакціями та іншими відомостями про клієнтів.

3. Підготовка даних (Data Preparation):

- Мета: Очищення, трансформація та форматування даних для підготовки до моделювання.
- Приклад: Видалення дублікатів, обробка відсутніх значень та конвертація форматів.

4. Моделювання (Modeling):

- Мета: Вибір та навчання моделей для вирішення задач проєкту.
- Приклад: Застосування алгоритмів машинного навчання для створення моделі виявлення шахрайства.

5. Оцінка (Evaluation):

- Мета: Оцінка ефективності моделі на основі визначених критеріїв.
- Приклад: Вимірювання точності та чутливості моделі виявлення шахрайства.

6. Розгортання (Deployment):

- Мета: Впровадження та використання результатів проєкту в реальному середовищі.
- Приклад: Впровадження системи виявлення шахрайства в банківській системі для автоматичної обробки транзакцій.

▼ Збір та обробка даних в ML, джерела даних та їх особливості

Збір та обробка даних

Збір даних - це перший та один із найважливіших етапів у розробці ML моделей. Від якості та репрезентативності даних залежить ефективність та точність моделі.

1. Джерела даних:

- *Структуровані дані:* Це дані, які організовані у вигляді таблиць або баз даних, де кожен стовпець відповідає конкретному атрибуту, а кожен рядок - конкретному екземпляру. Наприклад, CSV файли, бази даних SQL.
- *Неструктуровані дані:* Це дані, які не мають чіткої організації, такі як текстові документи, аудіо- та відеофайли, зображення тощо.

2. Особливості даних:

- *Розмір даних:* Великий обсяг даних може вимагати спеціальних підходів до зберігання та обробки, таких як розподілені системи або використання хмарних обчислень.
- *Якість даних:* Якість даних визначається їхньою чистотою, актуальністю та повнотою. Неправильні або неповні дані можуть призвести до неправильних висновків моделі.
- *Нерівномірність класів:* У задачах класифікації можуть виникати проблеми, коли один клас має значно більше представників, ніж інші. Це може вплинути на навчання моделі та її точність.

3. Техніки збору та обробки даних:


- *Веб-скрапінг:* Це процес автоматичного збору даних з Інтернету. Використовується для отримання даних з веб-сайтів, які не надають API для доступу до даних.
- *Перетворення формату:* Деякі дані можуть зберігатися у форматі, який не підходить для ML моделей. Наприклад, текст потрібно перетворити у числовий формат за допомогою векторизації.
- *Очищення даних:* Це процес виявлення та видалення неправильних, відсутніх або непотрібних даних.

Збір та обробка даних є критичними етапами в процесі розробки ML моделей. Важливо використовувати належні методи для забезпечення

якості та репрезентативності даних, що веде до створення ефективних та точних моделей.

Розподіл даних на тренувальний, валідаційний та тестувальних набори

Розподіл даних на тренувальний, валідаційний та тестувальний набори є ключовим етапом у розробці моделей машинного навчання. Такий розподіл допомагає в оцінці та порівнянні ефективності різних моделей, а також уникненні перенавчання (overfitting).



1. Тренувальний набір (Training set):

- Це частина даних, яка використовується для навчання моделі. Модель "вивчає" зв'язки між вхідними функціями та їхніми відповідями на цьому наборі даних.

2. Валідаційний набір (Validation set):

- Це незалежна від тренувального набору частина даних, яка використовується для налаштування гіперпараметрів моделі та оцінки її загальної ефективності під час тренування. Валідаційний набір дозволяє контролювати перенавчання та оптимізувати параметри моделі.

3. Тестувальний набір (Test set):


- Це окрема від тренувального та валідаційного наборів частина даних, яка використовується для оцінки фінальної ефективності моделі. Тестувальний набір ніколи не використовується під час

тренування чи валідації моделі, щоб забезпечити об'єктивну оцінку її роботи на нових даних.

4. Перехресна перевірка (Cross-validation):

- Це метод, при якому весь набір даних розбивається на кілька неперекриваючихся піднаборів, аналогічних тренувальному та валідаційному наборам. Модель тренується та оцінюється кілька разів, кожен раз використовуючи інші комбінації тренувального та валідаційного наборів. Цей метод дозволяє краще уникнути перенавчання та забезпечує більш об'єктивну оцінку ефективності моделі.


Розподіл даних на тренувальний, валідаційний та тестувальний набори є важливою практикою для забезпечення надійності та ефективності моделей машинного навчання.



Перехресна перевірка (Cross-validation)

Перехресна перевірка (cross-validation) є важливим методом для оцінки ефективності моделей машинного навчання та уникнення перенавчання.

CROSS VALIDATION, EXPLAINED



1. Крос-валідаційні підходи:

- *K-fold Cross-Validation*: Весь набір даних розбивається на k різних піднаборів (folds). Потім модель тренується k разів, кожен раз використовуючи інший fold для валідації, а решта даних - для тренування. Після цього середній показник ефективності розраховується на основі результатів кожної ітерації.
- *Stratified K-fold Cross-Validation*: Це варіація K-fold Cross-Validation, де зберігається пропорція класів у кожному фолді, що допомагає забезпечити більш об'єктивну оцінку ефективності для нерівномірних класів.

2. Переваги перехресної перевірки:


- Дозволяє отримати більш надійну оцінку ефективності моделі, оскільки вона оцінюється на кількох незалежних вибірках даних.

- Допомогає уникнути перенавчання, оскільки модель оцінюється на даних, які не брали участь у її тренуванні.

3. Недоліки перехресної перевірки:

- Може бути дуже обчислювально витратним, особливо для великих наборів даних та складних моделей.
- Для деяких задач може бути складно побудувати адекватну крос-валідаційну схему, наприклад, для даних з часовою залежністю.

Перехресна перевірка є потужним інструментом для оцінки ефективності моделей машинного навчання і використовується для забезпечення надійності та об'єктивності результатів.



▼ Огляд основних інструментів в ML з використанням Python

NumPy, Pandas, Matplotlib, Scikit-Learn, Jupyter Notebook/Lab - одні з ключових базових інструментів, які широко використовуються у сфері машинного навчання з використанням мови програмування Python. Ці інструменти допомагають в роботі з даними, візуалізації результатів, реалізації моделей та оцінці їх ефективності.

1. NumPy:

- NumPy використовується для виконання операцій над масивами, що робить його важливим для обробки даних у машинному навчанні. Він також надає велику кількість математичних функцій, що дозволяє легко виконувати операції лінійної алгебри, статистики та інших наукових обчислень.
- Документація: <https://numpy.org>

2. Pandas:

- Pandas забезпечує зручний інтерфейс для завантаження, очищення, обробки та аналізу даних. Вона може працювати з різноманітними джерелами даних, такими як CSV файли, бази даних SQL, Excel аркуші та багато іншого. DataFrame - основна структура даних у Pandas, яка дозволяє зручно виконувати операції з табличними даними.
- Документація: <https://pandas.pydata.org>

3. Matplotlib:

- Matplotlib є основним інструментом для візуалізації даних у Python. Вона підтримує різноманітні типи графіків, включаючи лінійні та кругові діаграми, гістограми, точкові графіки тощо. З Matplotlib можна створювати візуалізації, які допомагають зрозуміти дані та представити результати аналізу.
- Документація: <https://matplotlib.org>

4. Scikit-Learn:

- Scikit-Learn - це велика бібліотека для машинного навчання, яка містить реалізації багатьох алгоритмів навчання, включаючи

класифікацію, регресію, кластеризацію та інше. Вона також містить інструменти для підготовки даних, валідації моделей, підбору гіперпараметрів та оцінки ефективності моделей.

- Документація: <https://scikit-learn.org/stable/>

5. Jupyter Notebook/Lab:

- Jupyter Notebook та Jupyter Lab надають інтерактивне середовище для виконання коду Python, а також для створення документів, що містять код, візуалізації та пояснювальний текст. Це дозволяє проводити експерименти, демонструвати результати та спільно працювати з іншими науковцями даних у зручний спосіб.
- Документація: <https://jupyter.org>

Ці інструменти у поєднанні надають потужний інструментарій для розробки та реалізації моделей машинного навчання з використанням Python. Вони допомагають зробити процес обробки даних, створення та оцінки моделей більш ефективним та продуктивним.